설비 고장을 예측하는 AI 데이터 분석

Pandas 집계·기초 통계

그룹 통계와 상관관계

posco

CONTENTS

목차

01 **그룹별 통계** 대푯값과 흩어짐 · 여러 통계를 한 표로 · 두 기준 표

02 **상관관계** 두 값이 함께 움직이는 정도 · 상관은 인과가 아니다

03 **종합 실습** 설비 상태 진단 리포트 한 장 만들기

posco

posco

01

그룹별 통계

대푯값과 흩어짐 · 여러 통계를 한 표로 · 두 기준 표

posco

이미 배운 통계량, 오늘 달라지는 것

통계량 자체는 앞 단원에서 다 배웠다 —오늘 새로운 것은 그룹 단위로 낸다는 점

통계량	무엇을 알려 주나	그룹별로 내면
평균 mean	값들을 대표하는 가운데	그룹마다 수준이 다른지
중앙값 median	극단값에 흔들리지 않는 가운데	평균과 나란히 놓아 치우침 판정
분산 var	흩어진 정도 — 단위가 제곱	그룹마다 얼마나 안정적인지
표준편차 std	흩어진 정도 — 원래 단위	평균 옆에 반드시 함께
최솟값 • 최댓값	양 끝값	그룹의 폭과 이상값 후보

posco

그룹별로 내면 무엇이 달라지나

함수는 그대로 — 앞에 그룹 기준만 붙이면 숫자 하나가 그룹 수만큼으로 늘어난다

CODE

```
df = pd.read_csv('data/14_hydraulic.csv')

print(df['온도'].mean().round(2))      # 45.34   전체 하나
print(df['온도'].std().round(2))       # 8.04

print(df.groupby('냉각기상태')['온도'].mean().round(2))
# 고장 54.67 · 저하 45.46 · 정상 35.89

print(df.groupby('냉각기상태')['온도'].std().round(2))
# 고장 3.76 · 저하 1.47 · 정상 0.36
```

전체 편차 8.04는 그룹 사이의 거리가 만든 값 — 그룹 안에서는 훨씬 촘촘하다

posco

평균이 비슷해도 같은 상태는 아니다

밸브 네 상태의 평균 온도는 1.2도 안에 다 들어온다 — 그런데

밸브 상태별 평균 온도 44.86 · 45.11 · 45.86 · 46.02

네 상태는 같은 상태일까?

답

아니다

고장 비율은 19.7%에서 73.7%까지 — 거의 네 배 차이

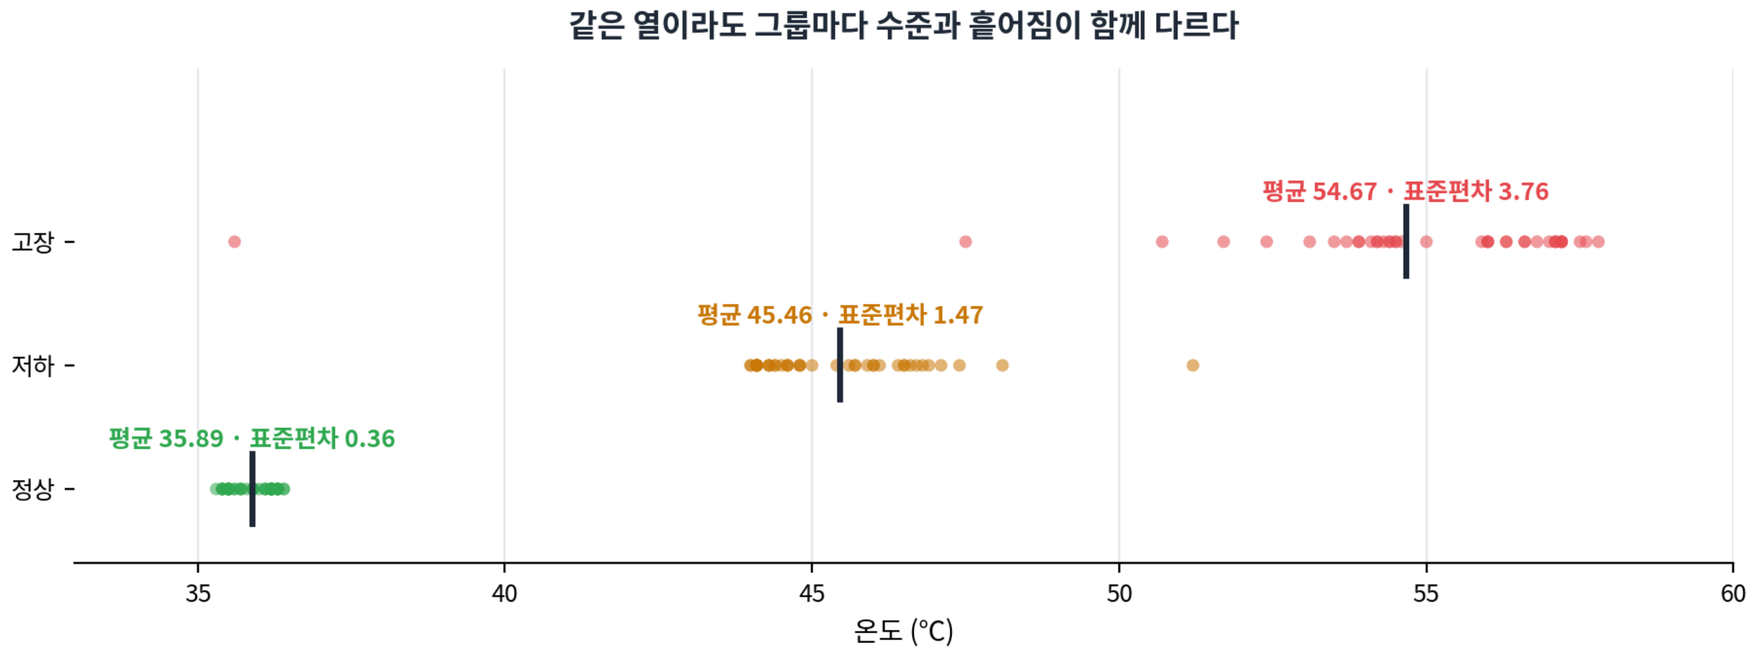
왜 안 보였나

평균은 가운데만 알려 준다

가운데가 같아도 흩어짐과 결과가 다를 수 있음 — 그래서 통계를 여러 개 본다

수준과 흩어짐은 함께 봐야 한다

냉각기 세 상태의 온도를 점으로 흩뿌린 그림 —평균 막대와 표준편차를 함께 표시



정상은 36도 부근에 촘촘히(0.36) · 고장은 55도 부근에 넓게(3.76) — 평균만 보면 흩어짐을 놓친다

정상은 한 점에 뭉쳐 있고, 고장은 오른쪽에서 넓게 퍼져 있다.

평균이 오르면서 흩어짐도 함께 커지는 것이 설비 상태 악화의 전형적인 모습

분산과 표준편차 비교

결정적 차이는 단위 — 둘 중 하나만 외운다면 표준편차

구분	분산 var	표준편차 std
의미	흩어짐 정도	흩어짐 정도
단위	❌ 단위의 제곱	✅ 원래 단위
관계	std의 제곱	var의 제곱근

실무에서는 **표준편차를 훨씬 많이 사용** —단위가 원래 데이터와 같아 바로 해석되기 때문

posco

설비 상태 4분면

평균과 표준편차를 한 쌍으로 묶어 설비 데이터를 진단하는 사고 틀

01 • 이상적 안정

평균 정상 + 편차 작음

적절한 온도에서 안정적으로 돌아가는 가장 이상적인 상태

02 • 불안정 주의

평균 정상 +편차 큼

평균은 괜찮아 보여도 온도가 들쭉날쭉 요동치는 불안정 신호

03 • 일관된 과부하

평균 높음 + 편차 작음

꾸준히 높은 온도로 안정적으로 운영 —과부하 상태 의심

04 • 고위험

평균 높음 +편차 큼

뜨거운데다 불안정하기까지 한, 가장 위험한 상태

설비 진단의 황금 규칙 —평균과 표준편차는 항상 한 쌍으로

posco

agg로 여러 통계 한 번에

agg — aggregate, 여러 통계를 한 번에 구해 표로 정리

01 • 사용법

한 번에 여러 통계

여러 통계를
한 번에 구해 표로

평균·표준편차·최댓값을 매번 따로 치면 결과를 눈눈으로 짜맞춰야 함

02 • 전달 방법

이름을 목록으로

통계 이름을
목록으로 묶어 전달

따옴표로 감싼 통계 이름을 리스트로 넘기면 모든 그룹에 동일 계산

03 • 조합

자유로운 통계 선택

mean • std • var
max • min • median • count
자유 조합

필요한 통계 묶음만 골라 한 표에 정리

모든 그룹에 똑같은 통계 묶음이 빠짐없이 계산되어 비교 기준이 통일됨

posco

agg 리스트 방식 코드

통계 이름을 목록으로 묶어 전달 — 그룹이 행, 통계가 열인 표

CODE

```
print(df.groupby('냉각기상태')['온도'].agg(['mean', 'std', 'max']).round(2))
#          mean   std   max
# 고장    54.67  3.76  57.8
# 저하    45.46  1.47  51.2
# 정상    35.89  0.36  36.4
```

통계 세 개를 한 표에 —따로 구해 눈으로 짜맞추던 것과 비교하면 훨씬 안전
다만 결과 열 이름이 영어로 나와서 보고서에 쓰기엔 친절하지 않음

행이 그룹 · 열이 통계 —세로로 읽으면 편차 3.76 · 1.47 · 0.36 이 한눈에 들어온다

posco

agg이름 붙이기 코드

결과이름 = (원본열, 통계) 형태로 정리 — named aggregation

CODE

```
summary = df.groupby('냉각기상태').agg(
    평균온도=('온도', 'mean'),
    온도편차=('온도', 'std'),
    평균진동=('진동', 'mean'),
    측정수=('온도', 'count'),
).round(2)
print(summary)
#        평균온도  온도편차  평균진동  측정수
# 고장     54.67    3.76    0.69    40
# 저하     45.46    1.47    0.61    40
# 정상     35.89    0.36    0.55    40
```

등호 왼쪽 =결과 열 이름(우리말 자유) · 등호 오른쪽 =(원본 열, 통계 이름)
여러 열의 다양한 통계를 한 표로 정리하는 **가장 깔끔한 방법**

온도와 진동 두 열을 한 표에 섞어 담았다 —목록 방식으로는 안 되는 일

posco

이름 붙이기 방식을 권장하는 이유

named aggregation은 최신 판다스의 권장 문법

01 · 권장

최신 판다스의 표준

판다스가 공식으로
권장하는 안전한 방법

버전이 올라가도 사라지지 않고 그대로 작동

02 · 중괄호 방식

쓸 수는 있지만

중괄호 한 겹은 되고
두 겹은 오류

{'온도': 'mean'} 은 지금도 잘 돌아감 · 그 안에 중괄호를 넣어 이름을 붙이는 방식만 제거됨

03 · 결론

버전 문제 없이

처음부터 권장 방식으로
이름 붙이기로 익혀 두기

여러 열의 통계를 한 표에 담고 결과 열 이름까지 우리말로 줄 수 있는 것은 이 방식뿐

실습 1. 여러 통계를 한 표로 모으기

따로 구하던 통계 여러 개를 한 번에 구해 하나의 표로 정리

목표

합격•불합격 두 그룹의 온도와 냉각효율 통계를 한 표에 모아 차이를 확인

단계

① 품질검사 파일을 읽어 검사 결과별 건수를 먼저 확인

② 검사 결과로 그룹을 나눠 온도의 평균·표준편차·최댓값을 목록 방식으로 한 번에 구하기

③ 이름 붙이기 방식으로 평균온도·평균냉각효율·측정수를 담은 표 만들기

④ 두 그룹의 숫자를 비교해 불합격 쪽의 특징을 한 문장으로 말하기

예상 결과

불합격은 평균 온도 55.84 • 냉각효율 19.65 • 합격은 35.91 과 46.88

실습 1 결과 해석

표를 가로로도 세로로도 읽어 보기

원리

행은 그룹,
열은 통계

한 표에 모아 놓으면 가로로는 한 그룹의 모습이,
세로로는 그룹 사이의 차이가 보인다.

따로 구하면 세로 읽기가 안 된다.

함정

12건짜리 통계를 단정해서 읽기

불합격은 12건뿐이다.
평균 55.84는 참고값이지 결론이 아니다.

그래서 측정수를 표에 함께 넣는다.

검산

측정수 188 · 12

측정수 열의 합이
200이 되어야 한다.

안 맞으면 빈 칸이 있어 count 에서 빠진 것이다
.

posco

실습 1 정답

CODE

```
import pandas as pd

qc = pd.read_csv('data/14_hydraulic_qc.csv')
print(qc['검사결과'].value_counts())     # 합격 188 · 불합격 12

print(qc.groupby('검사결과')['온도'].agg(['mean', 'std', 'max']).round(2))
#          mean   std   max
# 불합격   55.84  1.32  57.5
# 합격     35.91  0.97  44.7

table = qc.groupby('검사결과').agg(
    평균온도=('온도', 'mean'),
    평균냉각효율=('냉각효율', 'mean'),
    측정수=('온도', 'count'),
).round(2)
print(table)   # 불합격 55.84 / 19.65 / 12  · 합격 35.91 / 46.88 / 188
```

두 방식의 결과 열 이름을 비교할 것 — 아래쪽은 그대로 보고서에 붙일 수 있다

posco

그룹 통계를 원래 줄에 되돌려 붙이기 — transform

같은 평균을 구하는데 결과의 줄 수가 다르다 — 방금 만든 표와 무엇이 다른가

구분	mean	transform('mean')
결과 줄 수	그룹 수만큼 (3줄)	원래 행 수만큼 (120줄)
쓰임	그룹끼리 비교하는 표	원본에 새 열로 붙이기
이어서 할 일	정렬해서 우선순위	내 값이 그룹 평균에서 얼마나 떨어졌나

결측을 그룹 평균으로 채우는 일에도 이 도구를 쓴다 — 다음 단원에서 다시 나온다

transform 코드 — 줄 수를 지키며 그룹 평균 붙이기

mean은 3줄, transform은 120줄 —그래서 새 열로 붙는다

CODE

```
print(df.groupby('냉각기상태')['온도'].mean().shape)        # (3,)
print(df.groupby('냉각기상태')['온도'].transform('mean').shape)  # (120,)



marked = df.copy()
marked['그룹평균'] = marked.groupby('냉각기상태')['온도'].transform('mean').round(2)
marked['편차'] = (marked['온도'] - marked['그룹평균']).round(2)
print(marked[['냉각기상태', '온도', '그룹평균', '편차']].head(3))
#   냉각기상태    온도  그룹평균     편차
#       고장  35.6  54.67 -19.07
#       고장  47.5  54.67  -7.17
print(marked.groupby('냉각기상태')['편차'].sum().round(2).to_dict())
# {'고장': -0.1, '저하': 0.2, '정상': -0.2}   그룹마다 거의 0
```

posco

두 기준 표를 한 번에 — pivot_table

행 기준 • 열 기준 • 값 • 계산 방법을 이름으로 지정

구분	groupby + unstack	pivot_table
쓰는 법	두 단계로 나눠 씀	한 줄에 index • columns • values
합계 행•열	직접 계산해 붙여야 함	margins=True 한 줄
결과	같음	같음

결과는 같으므로 편한 쪽을 쓰면 된다 — 합계까지 필요하면 pivot_table 이 짧다

posco

pivot_table 코드 — margins 로 합계까지

index · columns · values · aggfunc 네 이름만 채우면 된다

CODE

```
pd.pivot_table(df, index='밸브상태', columns='운전부하',
               values='온도', aggfunc='mean').round(2)
#         고부하   저부하
# 경미     42.20   47.52
# 심각     45.25   47.09
# 정상     39.34   49.40
# 지연     43.75   49.79

pd.pivot_table(df, index='밸브상태', columns='운전부하', values='온도',
               aggfunc='mean', margins=True, margins_name='전체').round(2)
#         고부하   저부하    전체
# 경미     42.20   47.52   44.86
#  ...       ...     ...     ...
# 전체     41.85   48.82   45.34   <- 마지막 줄이 전체 평균
```

오른쪽 아래 45.34는 전체 평균 — 앞 단원에서 본 그 숫자가 표 구석에 다시 나온다

posco

실습 2. 되돌려 붙이고 두 기준 표로 보기

transform으로 편차 열을 만들고, pivot_table로 두 기준 표를 만들기

목표

그룹 평균에서 가장 멀리 떨어진 사이클을 찾고, 두 기준 표로 전체를 훑기

단계

① 유압 사이클 파일을 읽어 사본을 만들고 냉각기 상태별 온도 평균을 새 열로 붙이기

② 각 사이클의 온도에서 그 열을 빼 편차 열을 만들고 앞 세 줄을 확인

③ 편차의 절댓값이 가장 큰 줄 하나를 찾아 어느 상태인지 확인

④ 밸브 상태를 행, 운전 부하를 열로 두고 온도 평균 표를 합계까지 붙여 만들기

예상 결과

편차 최대는 고장 그룹의 −19.07 • 표는 네 줄 두 칸에 합계가 붙어 다섯 줄 세 칸

실습 2 결과 해석

줄 수를 지킨다는 것이 왜 중요한가

원리

줄 수가 같아야 열로 붙는다

mean 은 3줄이라 120줄짜리 표에 못 붙는다.

transform 은 120줄 그대로라 새 열이 된다.
그것이 두 도구의 차이 전부다.

함정

전체 평균으로 빼는 것

고장 그룹의 35.6도와
정상 그룹의 35.6도는
뜻이 완전히 다르다.

비교 기준은 같은 상태끼리여야 한다.

검산

편차 합이 0

편차를 그룹별로 더하면 0에 가깝다.
평균에서 뺀 값이라 위아래가 상쇄된다.

0에서 멀면 계산이 틀린 것이다.

편차 −19.07은 고장으로 분류됐는데 온도는 정상 수준인 사이클 — 다른 지표를 봐야 한다

posco

실습 2 정답

되돌려 붙이기와 두 기준 표, 각각 한 줄씩

CODE

```
print(pd.pivot_table(marked, index='밸브상태', columns='운전부하', values='온도',
                     aggfunc='mean', margins=True, margins_name='전체').round(2))
#          고부하    저부하     전체
#  ...       ...       ...       ...
# 전체     41.85    48.82    45.34
```

02

상관관계

부호는 방향, 절댓값은 강도 · 상관은 인과가 아니다

posco

값 하나에서 값 사이로

지금까지는 열 하나의 성질을 봤다 — 이제 열 두 개가 함께 움직이는지를 본다

01 · 지금까지

열 하나의 가운데와 흩어짐

평균 · 중앙값 · 표준편차는 모두 열 하나 안에서 끝나는 이야기였다.

02 · 이제부터

열 둘이 함께 움직이는가

온도가 오를 때 진동도 오르는가. 냉각효율은 반대대로 내려가는가.

03 · 왜

먼저 파 볼 쌍을 골라내기 위해

센서가 열 개면 짝은 마흔다섯이다. 어디부터 볼지 정해 주는 것이 상관계수다.

함께 움직인다는 관찰이지 원인을 밝힌 것이 아니라는 점은 뒤에서 따로 다룬다

상관계수는 두 가지를 말해 준다

–1 에서 1 사이의 한 숫자 — 부호가 방향을, 절댓값이 강도를 나타냄

01 · 부호

＋ 는 같은 방향
– 는 반대 방향

온도-진동 0.931 은 함께 오른다는 뜻,
온도-냉각효율 – 0.951 은 하나가 오르면 다른가 내린다는 뜻.

02 · 절댓값

1 에 가까울수록
강하게 붙어 있음

0.931 과 – 0.951 은 부호만 다를 뿐 강도는 거다.
0 에 가까우면 함께 움직이는 기미가 없다는 뜻.

03 · 읽는 순서

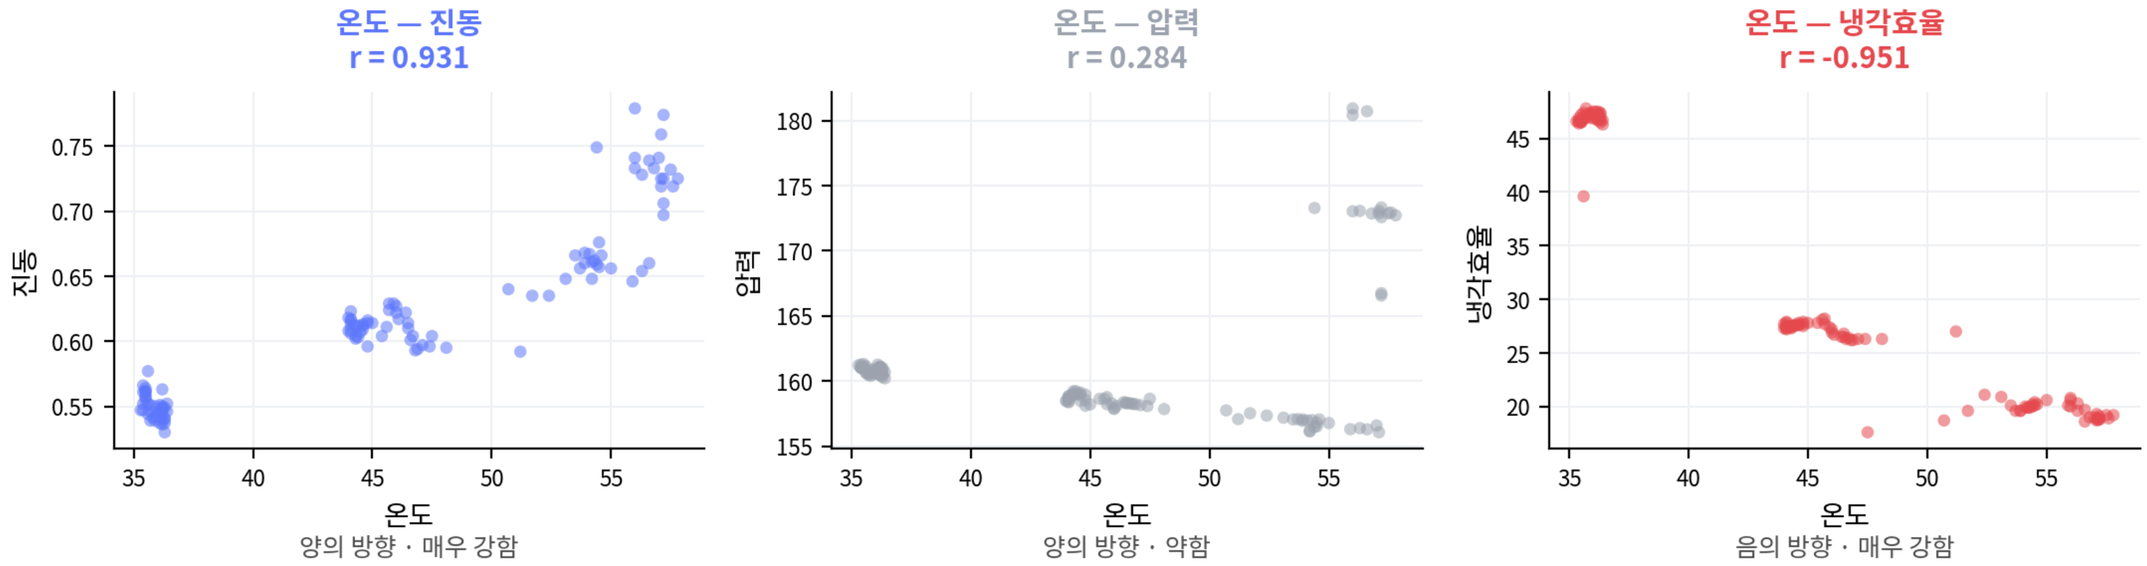
부호 먼저,
절댓값 나중

부호로 방향을 정하고 절댓값으로 세기를 잰다.
–0.9 는 약한 것이 아니라 아주 강한 음의 관계다.
.

가장 흔한 실수 — 음수를 보고 「관계가 약하다」고 읽는 것

산점도로 보면 숫자의 뜻이 보인다

같은 온도 열을 세 짝과 각각 그려 본 그림 — 점의 모양이 곧 상관계수



점이 한 줄로 모일수록 절댓값이 크고, 오른쪽 아래로 흐르면 음수다

점이 한 줄로 모일수록 절댓값이 크고, 흩어질수록 0에 가깝다.

숫자만 보고 판단하기 전에 한 번 그려 보는 습관 — 같은 0.3도 모양이 다를 수 있다

posco

corr 로 두 값의 상관계수 구하기

괄호 안에 비교할 열을 통째로 넣는다 — 열 이름 글자가 아니라 열 그 자체

CODE

```
df = pd.read_csv('data/14_hydraulic.csv')

print(round(df['온도'].corr(df['진동']), 3))       #  0.931
print(round(df['온도'].corr(df['압력']), 3))       #  0.284
print(round(df['온도'].corr(df['냉각효율']), 3))   # -0.951

# 주의) 괄호 안에 글자를 넣으면 오류
# df['온도'].corr('진동')
# AttributeError 발생 — 비교할 열을 통째로 넘겨야 함
```

빈 칸이 있는 행은 계산에서 자동으로 빠진다 — 몇 건으로 잰 값인지 함께 확인할 것

상관 행렬 — 모든 짝을 한 번에

열 네 개를 통째로 넣으면 모든 짝의 상관계수가 한 표로 나옴

대각선은 언제나 1 · 대각선을 접으면 위아래가 같다

	온도	진동	압력	냉각효율
온도	1.000	0.931	0.284	-0.951
진동	0.931	1.000	0.524	-0.862
압력	0.284	0.524	1.000	-0.131
냉각효율	-0.951	-0.862	-0.131	1.000

볼 곳은 대각선 위쪽 절반뿐 — 온도-냉각효율 −0.951 과 온도-진동 0.931 이 먼저 눈에 들어와야 한다

온도-냉각효율 −0.951 과 온도-진동 0.931 이 가장 진하다 — 여기부터 파 보면 된다.

볼 곳은 대각선 위쪽 절반뿐 — 절댓값이 큰 칸부터 순서대로 확인

절댓값으로 판단하는 상관 강도

구간 기준은 결론이 아니라 어디부터 볼지 정하는 도구

절댓값 구간	해석	우리 데이터의 예
0.9 이상	매우 강한 상관	온도-냉각효율 −0.951 · 온도-진동 0.931
0.7 ~ 0.9	강한 상관	진동-냉각효율 −0.862
0.4 ~ 0.7	중간 상관	진동-압력 0.524
0.2 ~ 0.4	약한 상관	온도-압력 0.284
0.2 미만	거의 관계 없음	압력-냉각효율 −0.131

실습 3. 두 센서의 관계 재어 보기

짝을 지어 상관계수를 구하고, 여러 열을 한 번에 넣어 표로 확인

목표

유압 네 열의 상관을 하나씩 그리고 한 번에 구해 가장 강한 짝을 찾기

단계

① 유압 사이클 파일을 읽어 온도와 진동의 상관계수를 구하기

② 온도와 압력, 온도와 냉각효율도 같은 방법으로 구해 세 값을 비교

③ 네 열을 통째로 넣어 모든 짝의 상관을 한 표로 만들기

④ 표에서 절댓값이 가장 큰 짝과 가장 작은 짝을 각각 찾기

예상 결과

가장 강한 짝은 온도-냉각효율 −0.951 • 가장 약한 짝은 압력-냉각효율 −0.131

실습 3 결과 해석

숫자를 읽고 물리적으로 말이 되는지 따져 보기

원리

부호는 방향,
절댓값은 강도

−0.951 은 아주 강한 관계다.
방향만 반대일 뿐이다.

「가장 강한」을 찾을 때는 절댓값으로 비교한다.

함정

음수를 약하다고
읽는 것

0.284 보다 −0.951 이 훨씬 강하다.

부호를 떼고 크기만 보는 연습을 먼저 한다.

검산

대각선이 전부 1

표의 대각선이 1.000 이고
위아래가 대칭이면 제대로 만든 것이다.

대칭이 아니면 열을 잘못 넣은 것이다.

posco

실습 3 정답

짝으로 하나씩, 그리고 여러 열을 한 번에

CODE

```
df = pd.read_csv('data/14_hydraulic.csv')

print(round(df['온도'].corr(df['진동']), 3))        #  0.931
print(round(df['온도'].corr(df['압력']), 3))        #  0.284
print(round(df['온도'].corr(df['냉각효율']), 3))    # -0.951

four = df[['온도', '진동', '압력', '냉각효율']]
print(four.corr().round(3))
#            온도     진동     압력   냉각효율
# 온도      1.000  0.931  0.284  -0.951
# 진동      0.931  1.000  0.524  -0.862
# 압력      0.284  0.524  1.000  -0.131
# 냉각효율 -0.951 -0.862 -0.131   1.000
```

표에서 가장 진한 짝은 온도-냉각효율 −0.951 — 절댓값으로 비교할 것

posco

상관은 인과가 아니다

함께 움직인다는 관찰일 뿐 — 무엇이 원인인지는 상관계수가 답해 주지 않음

01 • 말해 주는 것

두 값이 함께
움직였다는 사실

우리 데이터에서
온도와 냉각효율이 반대로 움직였다는 관찰 결과.

02 • 말해 주지 않는 것

무엇이 원인이고
무엇이 결과인지

냉각이 안 돼 뜨거워진 것인지,
뜨거워서 냉각 효율이 떨어진 것인지는 알 수 없
.

03 • 숨은 원인

둘 다 움직이게 한
제3의 원인

냉각기 상태가 나빠진 것이
둘 다에 영향을 준 것일 수도 있다.

원인을 말하기 전에 확인할 것

상관 결과를 손에 쥐었을 때 바로 다음에 해야 하는 일 세 가지

01 · 물리로 설명되나

작동 원리로
말이 되는가

냉각효율이 떨어지면 온도가 오른다는 것은
설비 원리로 설명된다.
설명이 안 되면 데이터를 의심한다.

02 · 제3의 원인

둘 다 움직이게 한
다른 요인이 있나

냉각기 상태별로 나눠 다시 재 보면
숨은 원인을 가릴 수 있다.

03 · 표본이 충분한가

몇 건으로
잰 값인가

열두 건으로 잰 상관계수는
연히 큰 값이 나오기 쉽다.
건수를 함께 확인한다.

이 셋을 통과하지 못한 상관은 보고서에 「원인」이라고 쓰지 않는다

posco

실습 4. 강한 짝 찾아내기

센서가 열 개인 표에서 상관 행렬을 만들고 볼 만한 짝만 골라내기

목표

품질검사 표의 센서 열 개로 상관 행렬을 만들고 기준을 정해 짝을 추리기

단계

① 품질검사 파일을 읽어 검사 결과를 뺀 센서 열만 골라내기

② 그 열들로 상관 행렬을 만들고 크기를 확인

③ 대각선을 뺀 짝의 개수를 세고, 절댓값 0.4 이상인 짝이 몇 개인지 확인

④ 기준을 0.95로 올려 다시 세고 상위 다섯 짝을 출력

예상 결과

짝은 모두 45개 • 0.4 이상이 42개 • 0.95 이상은 14개

실습 4 결과 해석

기준이 걸러 주지 못할 때 무엇을 할 것인가

원리

표를 목록으로 펴면 조건으로 고를 수 있다

상관 행렬은 10 × 10 표다. unstack 으로 100줄짜리 목록으로 펴면

앞 파트에서 배운 조건 필터와 정렬이 그대로 통한다.

함정

교과서 기준을 그대로 쓰는 것

0.4 기준으로는 45짝 중 42짝이 남는다.

걸러지지 않으면 기준이 아니라 데이터에 맞춰 올려야 한다.

검산

100 · 45 · 42 · 14

펴면 100줄, 대각선 기준 위쪽 절반만 남기면 45줄.

그중 0.4 이상 42짝, 0.95 이상 14짝이면 맞다.

posco

실습 4 정답

표를 목록으로 펴고 조건과 정렬로 추려 내기

CODE

```
qc = pd.read_csv('data/14_hydraulic_qc.csv')
sensor_cols = [c for c in qc.columns if c != '검사결과']
corr_matrix = qc[sensor_cols].corr()
print(corr_matrix.shape)                    # (10, 10)

pairs = corr_matrix.unstack()               # 표를 목록으로 폄
print(len(pairs))                           # 100   10 x 10

upper = pairs[[a < b for a, b in pairs.index]]   # 대각선 위쪽 절반만
print(len(upper))                           # 45

print(int((upper.abs() >= 0.4).sum()))      # 42
print(int((upper.abs() >= 0.95).sum()))     # 14

print(upper.abs().sort_values(ascending=False).head(5).round(3).to_dict())
# {('배유온도', '온도'): 0.999, ('유량', '효율지수'): 0.999,
#  ('보조압력', '압력'): 0.993, ('냉각효율', '온도'): 0.983,
#  ('냉각출력', '유량'): 0.982}          짝이 괄호로 묶여 나온다
```

posco

03

종합 실습

세어 보고 · 합치고 · 나눠서 재고 · 관계를 본다 — 리포트 한 장으로

숫자에서 판단으로

집계 결과의 값어치는 누군가 그것을 읽고 행동을 바꿀 때 생긴다

01 · 빈도로

어디에 몰려 있는지

밸브 심각은 19건 중 14건이 고장이었다.
문제가 어느 그룹에 몰려 있는지 알려 준다.

02 · 그룹 통계로

얼마나 높고 얼마나 불안한지

냉각기 고장은 평균 54.67도에 편차 3.76이었다.
수준과 안정성을 함께 말해 준다.

03 · 상관으로

무엇과 함께 움직이는지

온도와 냉각효율이 −0.951이었다.
어느 값을 같이 감시해야 하는지 알려 준다.

셋을 각각 말하면 숫자 나열이고, 하나의 이야기로 엮으면 리포트가 된다

posco

발견 · 해석 · 행동 세 칸

리포트는 이 순서로 쓴다 — 사실을 먼저, 의미를 다음에, 제안을 마지막에

STEP 1 · 발견

숫자로 확인한 객관적 사실

「밸브 심각 19건 중 14건이 고장(73.7%)」처럼
수치와 함께 적는다. 판단은 아직 넣지 않는다.

STEP 2 · 해석

그 숫자가 무슨 뜻인지

평균·편차·상관의 언어로 설명한다.
원인 단정은 피하고 「함께 움직인다」까지만 쓴다.

STEP 3 · 행동

그래서 무엇을 먼저 볼 것인지

우선 점검 대상과 계속 감시할 항목을 적는다.
읽는 사람이 바로 할 수 있는 일이어야 한다.

세 칸이 다 채워지지 않으면 아직 리포트가 아니다 — 특히 세 번째 칸이 자주 빈다

posco

실습 5. 설비 상태 진단 리포트 만들기

앞 단계 —실무 분석가가 새 데이터를 받았을 때 하는 순서 그대로 •확인하고 붙이고 묶고 재기

목표

사이클 로그에 정비 기준을 붙이고 구간으로 묶어 상태별 진단표까지 만들기

단계

① 유압 사이클 파일과 정비 기준 파일을 각각 읽어 크기와 칸 이름을 확인

② 왼쪽 표가 다 남도록 두 표를 합치고, 줄 수가 그대로인지 확인

③ 사본을 만들어 온도를 세 구간으로 묶은 새 칸을 붙이기

④ 냉각기 상태별로 건수·평균·흩어짐과 기준표에서 온 값을 한 표로 모으기

예상 결과

합친 표는 120줄 12칸 • 구간은 낮음 41 • 보통 40 • 높음 39 • 진단표는 세 줄 여섯 칸

실습 5. 설비 상태 진단 리포트 만들기

뒤 단계 — 만든 표를 읽는다 · 교차표와 상관으로 근거를 모으고 순서를 정해 문장으로

목표

교차표와 상관으로 근거를 모으고 우선순위를 정해 세 문단으로 옮기기

단계

⑤ 냉각기 상태를 행, 온도 구간을 열로 놓은 개수 표 만들기

⑥ 온도와 냉각효율, 온도와 진동이 어떤 관계인지 각각 수치로 재기

⑦ 위험도가 높은 순서로, 같으면 평균 온도가 높은 순서로 진단표를 세우기

⑧ 결과를 기반으로 판단 가능한 내용을 두 줄 이내로 쓰기 (##과 @@이 강한 상관관계를 가지고 있다 / 강하게 반대로 움직인다 등)

예상 결과

교차표는 세 줄 세 칸 · 상관은 –0.951 과 0.931 · 맨 위는 고장(위험도 3 · 54.67도)

posco

실습 5 결과 해석

여덟 단계가 하나의 이야기로 이어지는가

원리

붙이고 • 묶고 • 재고 • 옮긴다

기준정보를 붙여야 판단 기준이 생기고, 구간으로 묶어야 분포가 보이고, 관계를 재야 함께 감시할 값이 정해진다.

마지막에 그것을 문장으로 옮긴다.

함정

합친 뒤 줄 수를 안 보는 것

기준표에 없는 상태가 하나라도 있으면 붙여온 칸이 빈 칸이 된다.

120이 그대로 120인지, 빈 칸이 0인지 먼저 확인한다.

검산

120 • 41/40/39 • 세 줄

합친 표 120줄, 구간은 41 · 40 · 39, 진단표는 세 줄.

진단표 측정수의 합도 120이어야 한다.

실습 5 정답

앞 단계 — 확인하고 · 붙이고 · 묶고 · 표로 모은다

CODE

```
import pandas as pd

cycle = pd.read_csv('data/14_hydraulic.csv')          # ① 확인
spec = pd.read_csv('data/14_hydraulic_std.csv')
print(cycle.shape, spec.shape)              # (120, 8) (4, 5)
print([c for c in cycle.columns if c in spec.columns])   # ['냉각기상태']

joined = cycle.merge(spec, on='냉각기상태', how='left')   # ② 붙이기
print(len(cycle), len(joined), joined.shape)   # 120 120 (120, 12)
print(int(joined['담당팀'].isna().sum()))       # 0   못 붙은 줄 없음

work = joined.copy()                        # ③ 구간 묶기
work['온도구간'] = pd.cut(work['온도'], bins=[0, 40, 50, 200],
                          labels=['낮음', '보통', '높음'])
print(work['온도구간'].value_counts().to_dict())
# {'낮음': 41, '보통': 40, '높음': 39}

diagnosis = work.groupby('냉각기상태').agg(          # ④ 진단표
    측정수=('온도', 'count'), 평균온도=('온도', 'mean'),
    온도편차=('온도', 'std'), 평균냉각효율=('냉각효율', 'mean'),
    위험도=('위험도', 'max'), 점검주기=('권장점검주기', 'max'),
).round(2)
print(diagnosis.shape, int(diagnosis['측정수'].sum()))   # (3, 6) 120
```

posco

실습 5 정답

뒤 단계 — 표를 만들고 • 관계를 재고 • 순서를 정한다

CODE

```
print(pd.crosstab(work['냉각기상태'], work['온도구간']))   # ⑤ 교차표
# 온도구간   낮음  보통  높음
# 고장         1    1   38      <- 고장인데 낮음 한 줄
# 저하         0   39    1
# 정상        40    0    0

print(round(work['온도'].corr(work['냉각효율']), 3))   # ⑥ -0.951
print(round(work['온도'].corr(work['진동']), 3))       #     0.931

print(diagnosis.sort_values(['위험도', '평균온도'],    # ⑦ 우선순위
                            ascending=[False, False]))
# 고장 40 · 54.67 · 3.76 · 20.12 · 위험도 3 ·   7일
# 저하 40 · 45.46 · 1.47 · 27.24 · 위험도 2 ·  60일
# 정상 40 · 35.89 · 0.36 · 46.96 · 위험도 1 · 180일
```

집계 파트 마무리

세어 보고 • 나눠서 재고 • 함께 움직이는지 본다 — 데이터를 처음 받았을 때 할 일

01 • 세어 보기

구성과 치우침을 먼저 확인

값별 개수와 비율. 치우친 데이터를 모르고 시작하면 뒤가 다 어긋난다.

02 • 나눠서 재기

그룹별 수준과 흩어짐을 함께

평균 옆에는 언제나 편차와 건수를. 표 하나로 모으면 비교가 쉬워진다.

03 • 관계 보기

함께 움직이는 짝 찾기

부호는 방향, 절댓값은 강도. 강한 짝은 답이 아니라 다음 질문이다.