설비 고장을 예측하는 AI 데이터 분석

결측치 처리

결측치 이해와 확인

posco

CONTENTS

목차

01 **결측치 이해와 확인** 결측치란 무엇인가, 위장된 결측치, 결측치 확인 방법

02 **결측치 제거와 대체** 결측치 제거, 결측치 대체, 처리 워크플로우

posco

posco

01

결측치 이해와 확인

결측치란 무엇인가 · 위장된 결측치 · 결측치 확인 방법

데이터 전처리란 무엇인가

분석 시간의 70~80%, 전처리에 투입되는 일

01 • 비중

분석 업무의 70~80% 전처리에 쓰이는 시간

멋진 모델 이전에 데이터를 깨끗하게 다듬는 손질이 먼저

02 • 현실

현장 데이터는 비거나 잘못된 값이 많음

센서 고장, 입력 실수 — 쓰레기를 넣으면 쓰기가 나오는 구조

03 • 첫 단추

전처리의 시작은 결측치 다루기

재료 손질이 부실하면 아무리 멋진 요리도 못 먹는 일과 같음

결측치란 무엇인가

Missing Value — 데이터 표에서 값이 비어 있는 칸

01 · 정의

데이터 표에서
값이 비어 있는 칸

엑셀 표에서 어떤 칸엔 값이, 어떤 칸엔 아무도 없는 그 빈 칸

02 · 컴퓨터의 반응

빈 칸을 만나면
계산이 멈추거나 에러

사람은 그냥 넘어가지만 컴퓨터는 평균을 내다가도 죽음

03 · 제조 데이터

센서가 많아
결측이 특히 흔함

설비에는 센서가 수백 개씩 붙어 빈 칸이 자주 발생

NaN의 정체

Not a Number — 판다스가 붙여 두는 "값 없음" 폿말

01 • 의미

Not a Number
숫자가 아님

빈 칸을 발견한 판다스가 자동으로 찍는 결측 표시

02 • 0으로 채우면

온도 0도와
기록 없음은 다른 일

빈 칸을 0으로 메우면 컴퓨터가 진짜 숫자 0으으로 오해

03 • 전염성

NaN이 끼면
결과까지 NaN

잉크 한 방울이 깨끗한 물을 흐리게 만드는 것과 같음

NaN과 None의 차이

이름은 둘이지만 판다스에선 똑같이 결측으로 잡힘

Q 1. **None은 무엇인가요?**

A. 순수 파이썬 자체의 빈 값. "아무것도 없음"을 나타내는 파이썬 기본 표현

Q 2. **NaN은 무엇인가요?**

A. 데이터 표 속 빈 숫자값. 판다스 같은 데이터 도구에서 숫자 칸이 비었을 때 쓰는 표시

Q 3. **둘을 구분해야 하나요?**

A. 판다스가 둘 다 결측으로 처리하니 괜찮음. 실무에서 자주 보는 건 NaN

결측치가 표에 보이는 모습

CSV에선 빈 칸, 판다스에선 NaN — 도구마다 옷만 다를 뿐 속은 같음

CSV 파일을 메모장으로 열면 결측 자리는 **그냥 빈 칸**으로 보임

그 파일을 판다스로 불러오는 순간 빈 칸이 **NaN으로 바뀌는 일**

실전에서는 앞부분 몇 줄만 띄워 빠르게 살피지만, 앞쪽에 NaN이 없다고 결측이 없다고 단정 금지

→ 눈으로 보는 확인과 숫자로 세는 확인을 늘 함께

측정시각	온도	압력	진동
10:00	25.3	1.02	2.4
10:01	NaN	1.05	2.5
10:02	25.7	NaN	2.6
10:03	26.1	1.04	NaN
10:04	NaN	1.06	2.7
10:05	26.4	1.03	2.5

설비센서 샘플 — 온도·압력·진동 컬럼 빈 칸이 빨갛게 강조됨

posco

센서 고장과 결측

"왜 값이 빠졌을까" — 이유를 알면 채울지 지울지 판단이 섬

01 · 고장

센서가 망가지면
그 순간 값이 빔

설비 부품인 만큼 언제든 고장 — 기록이 끊김

02 · 점검·교체

센서를 떼면
기록이 끊기는 구간

잠깐 점검은 앞뒤 값으로 채우는 게 자연스러움

03 · 환경

먼지·고온으로
일시적 측정 실패

통째로 고장 난 컬럼은 빼는 선택지가 합리적

수집•전송 과정의 결측

센서가 멀쩡해도 통신•합치기•옮기기 어디서든 결측 발생

01 • 통신 끊김

통신이 끊기면
그 사이 값이 사라짐

센서 → 통신선 → 중간 서버 → 저장 어디서든 든 문제 발생

02 • 합치기•변환

표를 합칠 때
시점이 안 맞아 빔

1분 단위 +5분 단위 합치면 시점 맞추는 과정 정에서 빈 칸 발생

03 • 자연스러운 현상

결측은
현실 데이터의 일상

데이터가 잘못된 게 아니라 발견·처리하는 능력의 문제

posco

위장된 결측치 — 숫자 0

멀쩡한 숫자인 척 숨어 있는 결측 — 대표 선수는 0

01 • 의심

가동 중인데 압력이 0 → 위장 결측

가동 중인 설비 압력이 진짜 0일 수 없음 — 서가 못 읽은 신호

02 • 정상

멈춘 설비의 속도 0 → 진짜 값

똑같은 0이라도 어떤 건 결측, 어떤 건 정상

03 • 판단

0의 의미는 사람이 맥락으로

컴퓨터가 못 가리는 일 — 데이터의 의미를 는 사람의 몫

강사용 샘플에도 가동 중인데 압력 0인 칸이 두 군데 존재

posco

위장된 결측치 — 센티넬 값

999, 9999 — 약속된 결측 표시, Sentinel

01 · SENTINEL VALUE

현실에 없는 값을 정해두고 "값 없음" 자리에 넣기로 한 약속

온도 **-999도**는 현실에 없는 값

옛날 시스템은 빈 칸을 저장할 방법이 없어서 이런 약속을 사용

데이터의 **최솟값·최댓값**을 보면 발견 가능

02 · 방치 시 영향

그대로 두면 평균이 크게 망가짐

컴퓨터는 -999를 진짜 숫자로 받아들임

진동값에 -999가 섞이면 평균이 **음수로 폭락**

불러올 때 **결측으로 인식시켜 줘야 함**

posco

빈 문자열과 공백도 결측

글자 컬럼에서도 결측은 일어남 — "비어 보이는 모든 것을 의심"

01 · 빈 문자열

글자 칸에
아무것도 없는 상태

설비명·작업자 이름 같은 텍스트 컬럼에서 발생

02 · 공백

스페이스만 들어가
판다스가 못 잡기도

공백을 정상값으로 취급해 결측으로 안 잡는 함정

03 · 원칙

비어 보이는
모든 것을 의심

NaN, 빈 칸, 0, -999, 공백 — 여러 얼굴의 결측

양옆 공백을 잘라 내는 정리 후, 그래도 빈 칸이면 결측으로 변환

posco

결측치와 데이터 타입

정수가 갑자기 소수로 보이면 — 거기 결측이 끼었다는 신호

원래 입력

1, 2, 3

NaN이 끼면

1.0, 2.0, 3.0

NaN이 기술적으로 실수형 — 정수 컬럼 전체가 자동으로 실수형으로 변환

분명 정수를 넣었는데 **1.0, 2.0, 3.0** 으로 보이는 일

오류가 아닌 **정상 동작**

→ **결측 의심의 단서**로 활용

처리 후 다시 **정수형으로 복원** 가능 (`astype("int")`)

posco

NaN의 비교 연산 함정

NaN은 자기 자신과 비교해도 "다르다"고 나오는 별난 값

01 · 잘못된 방법

```
df["온도"] == NaN
```

결과는 항상 거짓 → 분명 빈 칸인데 **결측 0개**로 나옴

02 · 올바른 방법

```
df["온도"].isna()
```

값 없는 것과 **값 없는 것**이 같다고 단정하기 어색

그래서 NaN은 등호로 비교 불가

초보가 가장 자주 당하는 함정 — "결측 0개"라는 오해

→ 결측은 반드시 isna 같은 전용 도구로

posco

결측 방치 시 통계 왜곡

"결측 빼고 계산"이 만드는 침묵의 오차 —그리고 위장 결측의 폭주

01 • 평균 왜곡

10개 중 2개가 결측이면
8개 평균이 됨

빠진 2개가 유난히 높았다면 실제보다 낮게 보임 → 설비 상태 오판

02 • 위장 결측

999 방치 시
평균이 음수로 폭락

정상값 2~4 사이인데 진동 평균이 음수 —완전 전혀 틀린 판단

03 • 전 통계 영향

합계•표준편차도
함께 흔들림

평균뿐 아니라 거의 모든 통계에서 왜곡 발생

결측 방치 시 시각화·모델 문제

그래프는 끊기고, 모델은 학습조차 시작 못 함 — 분석의 기초 공사

01 · 그래프

선이 뚝 끊기거나 점이 듬성듬성

시간에 따른 온도 변화선이 중간에 결측을 만나면 끊김

02 · 모델

학습 시작조차 못 하고 에러로 중단

대부분 머신러닝 도구는 빈 칸을 거부 — 엉하게 채우면 가짜를 진짜로 학습

03 · 결론

결측 처리는 모든 분석의 기초

통계·시각화·모델 — 어떤 분석을 하든 통과해야 할 관문

posco

결측이 타깃 컬럼에 있을 때

입력값 결측과 정답(Target) 결측은 처리 방식이 다름

01 • 입력값 결측

평균•앞뒤값으로 채워 활용 가능

온도·압력·진동 같은 입력 정보가 비면 채워서 살리기

02 • 정답 결측

추측으로 채우면 모델이 잘못 배움

가짜 정답을 가르치면 모델이 틀린 걸 외워 버림

03 • 원칙

정답이 빈 행은 채우지 말고 제거

센서값 결측 ≠정답 결측 —처리 방식을 분리

결측치 처리의 큰 그림

확인 → 판단 → 처리 — 의사가 진찰·치료방침·처방을 내리는 흐름과 같음

01 · 확인

결측이 어디에 얼마나 있는지 파악

어디가 아픈지도 모르고 약부터 먹는 일을 피함

02 · 판단

제거할지 대체할지 결정

너무 많은 컬럼은 빼고, 몇 개 안 되면 채워 살림 — 가장 사람다운 단계

03 · 처리

실제로 제거·대체 그리고 재확인

이번 모듈은 첫 단계 "확인"을 집중적으로 연습

posco

처리의 흐름 한눈에 보기

확인 → 판단 → 처리 → 재확인 — 닫히는 고리, 마지막 재확인을 빠뜨리지 말 것

STEP 1

확인

결측이 어디에 얼마나 있는지 파악

→

STEP 2

판단

컬럼·행별로 제거할지 대체할지 결정

→

STEP 3

처리

실제로 제거 또는 대체 실행

→

STEP 4

재확인

결측이 정말 0이 됐는지 다시 검증 — 초보가 가장 자주 건너뛰는 단계

일직선이 아닌 고리 — 결과가 어색하면 다시 확인으로 돌아오는 과정

실습 데이터와 두 Python 파일의 관계

스크립트의 입력 경로와 CSV 실제 행·열을 기준으로 정리합니다.

15_01 공정 데이터

파일 15_01_사출성형_공정.csv
크기 250행 × 22열
결측 총 475개
완전한 행 76개

결측 탐색, 컬럼별 개수·비율,
막대그래프·히트맵 실습에 사용합니다.

설비 로그 데이터

파일 15_사출성형_로그.csv
크기 16행 × 7열
일반 NaN 5개
위장값 압력 0 두 건, 속도 -999 두 건,
온도 999 한 건

na_values 예제로 위장 결측을 확인합니다.

15_02 스크립트의 입력

현재 두 스크립트의 PROC 경로는 모두
15_01_사출성형_공정.csv입니다.

별도 파일인 15_02_사출성형_공정.csv는
스크립트에서 읽지 않습니다.

따라서 실제 실행 기준으로 설명하고,
파일명만 보고 입력 데이터를 혼동하지
않도록 합니다.

실행 환경에 따라 파일 경로가 다르면 코드의 PROC·LOG 경로를 데이터 위치에 맞게 수정하세요.

공정 데이터 22개 컬럼 읽기

공정 상태·온도·압력·위치·계량 변수를 목적별로 묶었습니다.

기록과 품질·사이클

측정시각 — 측정한 시각
불량여부 — 불량 표시(0/1)
사이클시간 — 사이클 소요 시간
성형사이클 — 성형 사이클 측정값

온도와 사출 변수

배럴온도1~4 — 배럴 구간별 온도
호퍼온도 — 원료 투입부 온도
최대사출속도 — 최대 사출 속도
사출압력 — 사출 압력
스크루속도 — 스크루 속도

위치·압력·계량 변수

스크루위치·전환위치 — 위치 측정값
계량시간 — 원료 계량 시간
계량시작점·계량시작위치 — 계량 시작 측정값
최대사출압·전환압력 — 압력 측정값
최소쿠션 — 사출 후 남은 수지량 측정값
계량종료점·감압시간 — 계량 종료·감압 측정값

CSV에는 단위·세부 공정 정의가 없어, 일부 설명은 칼럼명에 근거한 일반적인 의미입니다.

공정 데이터의 실제 결측 현황

15_01 CSV(250행)에서 결측이 있는 컬럼은 12개입니다.

결측이 적은 컬럼

사출압력	1개 · 0.4%
스크루위치	3개 · 1.2%
전환위치	5개 · 2.0%
계량시간	9개 · 3.6%
계량시작점	9개 · 3.6%

완전 관측 컬럼은 결측 개수 0입니다.

결측이 중간 정도인 컬럼

최대사출압	34개 · 13.6%
전환압력	34개 · 13.6%
계량시작위치	34개 · 13.6%
스크루속도	60개 · 24.0%
최소쿠션	68개 · 27.2%

결측 비율이 높은 컬럼

계량종료점	109개 · 43.6%
감압시간	109개 · 43.6%

가장 큰 결측 비율은 두 컬럼의 43.6%입니다.

최대사출속도는 이 입력 데이터에서 결측이 없습니다.

총 결측 475개 · 결측이 하나 이상인 행 174개 · 결측이 없는 행 76개

로그 데이터 컬럼과 위장 결측

isna()만으로 찾을 수 있는 NaN과 도메인 지식으로 찾아야 하는 값을 구분합니다.

로그 7개 컬럼

측정시각 — 기록 시각
사출기 — 설비 구분
배럴온도 — 배럴 온도
사출압력 — 측정 압력
스크루속도 — 스크루 속도
누적샷 — 누적 샷 수
불량여부 — 불량 표시(0/1)

기록된 특수값

실제 NaN
사출기 1 · 배럴온도 2 · 사출압력 1 · 스크루속도 1

위장 결측 의심값
사출압력 0 두 건
스크루속도 -999 두 건
배럴온도 999 한 건

na_values 적용 결과

pd.read_csv(LOG, na_values=[-999, 999])

-999와 999는 NaN으로 읽힙니다.
로그 전체 결측 수는 5개에서 8개로 증가합니다.

사출압력 0은 이 설정에 포함되지 않으므로 별도 규칙이 필요합니다.

15_01 코드: 결측 확인과 시각화

확인 → 요약 → 그래프 → 다음 처리 단계로 이어집니다.

1. 데이터 구조 확인

pd.read_csv(PROC)
shape, head(), info(), describe()

250행 × 22열 구조와 각 컬럼의 채워진 값 수를 확인합니다.

2. 결측 수치화

df.isna().sum()
전체 결측 475개
컬럼별 비율 = 결측 수 ÷ 행 수 × 100
행별 결측 = df.isna().sum(axis=1)

isnull()은 isna()와 같고 notna()는 반대입니다.

3. 그림과 요약 파일

결측_막대.png — 컬럼별 결측 개수
결측_히트맵.png — 행·열의 결측 위치
결측요약.csv — 개수·비율·처리방향

처리방향 기준: 5% 미만 대체, 40% 이상 제거 고민, 나머지 검토

그래프의 한글 폰트는 설치된 글꼴을 찾아 설정하고, 음수 기호 표시도 별도로 설정합니다.

15_02 코드: 행·열 삭제

dropna 옵션은 유지할 데이터 양과 분석 목적에 맞춰 선택합니다.

행 삭제

df.dropna()
결측이 하나라도 있는 행 제거
250행 → 76행

전체 행의 69.6%가 제외되므로 결과 행 수와 손실률을 꼭 확인합니다.

열 삭제와 조건

dropna(axis=1)
결측이 있는 컬럼 제거
22열 → 결측 없는 10열

how='all' 완전히 빈 행만 제거
thresh=20 값이 20개 이상인 행 유지 → 162행
subset=['불량여부'] 해당 컬럼만 검사

컬럼을 직접 제거

결측 비율 계산 후 임계값으로 선택:
비율 > 40%인 실제 컬럼은
계량종료점, 감압시간

이 데이터에서 제거하면 250행 × 20열입니다.

삭제는 간단하지만 데이터 손실과 편향이 생길 수 있어 업무 맥락을 먼저 확인합니다.

15_02 코드: 결측 대체 방법

컬럼의 특성과 데이터 순서에 따라 대체 방법을 고릅니다.

수치형 값

상수 — 정해진 값으로 채움
평균 — 분포가 대칭적일 때 참고
중앙값 — 이상치 영향이 클 때 참고

예: 최대사출압 평균 1241.67, 중앙값 1238.4
두 방식 모두 대체 후 결측 0개

범주·시계열 값

최빈값 — 범주형 대표값
ffill() — 앞의 값으로 채움
bfill() — 뒤의 값으로 채움

로그의 사출기 결측은 최빈값으로 채우고,
측정시각 정렬 후 배럴온도에 앞·뒤
채우기를 적용합니다.

그룹별 대체

사출기별 평균으로 스크루속도를 채우려면
사출기 컬럼이 필요합니다.

현재 스크립트가 읽는 15_01 공정 CSV에는
사출기 컬럼이 없습니다.
따라서 실행 시 전체 평균 대체 분기로
처리됩니다.

대체값은 통계량·시간 순서·설비 그룹 등 데이터의 의미를 반영해 선택해야 합니다.

15_02 종합 처리와 코드 주의점

설명 주석과 실제 입력 데이터의 결과가 다를 수 있는 지점을 표시했습니다.

종합 처리의 실제 순서

① 최대사출속도, 감압시간 컬럼을 직접 삭제
② 남은 수치형 결측을 중앙값으로 대체
③ 결측 총합 확인

현재 입력 기준 결과:
결측 0개 · 250행 × 20열
사출성형_처리완료.csv 저장

삭제 비교 실습 결과

기준 데이터에서 최대사출속도·감압시간을 제거한 뒤:

행 삭제 결과 110행
중앙값 대체 결과 250행

행 삭제는 결측 있는 계량종료점 등이 남아 추가 행이 제외됩니다.

주석과 데이터의 불일치

실제 결측 >40% 컬럼:
계량종료점, 감압시간

일부 코드 주석·예시는 최대사출속도를 고결측 컬럼으로 적었지만, 이 CSV에서는 결측이 없습니다.

실행 결과와 주석을 데이터에 맞춰 함께 점검하세요.

15_02_사출성형_공정.csv는 별도 데이터이며 현재 두 스크립트의 PROC 입력으로 사용되지 않습니다.

실습 마무리: 확인에서 처리까지

결측을 무조건 삭제하거나 채우지 말고, 근거를 남기며 검증합니다.

확인

입력 파일·행·열 확인
NaN과 위장 결측 구분
컬럼별·행별 개수와 비율 계산
결측 위치를 그래프로 확인

판단·처리

결측 비율과 업무 중요도 검토
행·열 삭제의 손실량 비교
평균·중앙값·최빈값·앞뒤값 선택
그룹별 처리는 그룹 컬럼 확인

검증·저장

처리 후 결측 개수 재확인
행·열 수와 결과 분포 점검
처리 전·후 비교 기록
요약표와 처리 완료 CSV 저장

핵심: 실제로 읽은 데이터, 코드, 주석, 결과가 서로 일치하는지 확인합니다.