설비 고장을 예측하는 AI 데이터 분석

결측치 제거와 대체

사출성형 공정·설비 로그 데이터로 익히는 삭제, 대체, 검증

15_02 · 코드와 실제 데이터에 맞춘 실습 자료

학습 흐름: 삭제와 대체를 근거 있게 선택하기

처리 방법을 외우기보다, 어떤 데이터를 읽고 결과가 어떻게 달라지는지 확인합니다.

1. 데이터 확인

실제 입력 경로와 컬럼 확인
행·열 크기 및 결측 현황 확인
결측값과 위장 결측값 구별

2. 제거·대체

dropna의 axis·how·thresh·subset
fillna의 대표값·앞뒤 값·그룹별 값
삭제 손실과 대체 결과 비교

3. 검증·저장

처리 후 결측 개수와 행·열 확인
주석의 예상값을 실제 실행 결과와 대조
결과 파일의 저장 위치 확인

먼저 확인: 스크립트가 실제로 읽는 파일

두 스크립트의 PROC 경로는 15_01 공정 CSV입니다. 이름과 실제 입력 파일을 구분합니다.

실제 스크립트 입력

15_01_사출성형_공정.csv
250행 × 22열
결측 합계 475개

15_02 스크립트는 이 파일을 사용해 행·열 삭제와 수치 대체를 실습합니다.

별도 15_02 공정 파일

15_02_사출성형_공정.csv
250행 × 22열
사출기 컬럼이 포함됨

현재 스크립트에서는 이 CSV를 읽지 않습니다. 사출기별 그룹 대체가 이 파일에서 실행된다고 오해하지 않도록 주의합니다.

로그 파일

15_사출성형_로그.csv
16행 × 7열
실제 NaN 5개

최빈값 대체와 시간순 배럴온도 ffill·bfill 실습에 사용합니다.

실제 실행 환경에서 경로가 다르면 스크립트의 PROC·LOG 값을 데이터 위치에 맞게 바꿉니다.

공정 데이터 컬럼: 품질·온도·사출

측정값의 역할을 살펴본 뒤 결측을 삭제할지 채울지 판단합니다.

기록과 품질

측정시각 — 측정 시각
불량여부 — 불량 표시(0/1)
사이클시간 — 사이클 소요 시간
성형사이클 — 성형 사이클 측정값

온도

배럴온도1~4 — 배럴 구간별 온도
호퍼온도 — 원료 투입부 온도

온도 결측은 공정 단계와 시간 순서를 확인한 뒤 대체 방법을 정합니다.

사출·스크루

최대사출속도 — 최대 사출 속도
사출압력 — 사출 압력
스크루위치 — 스크루 위치
전환위치 — 공정 전환 위치
스크루속도 — 스크루 속도

CSV에는 측정 단위와 공정별 세부 정의가 따로 없어, 일부 설명은 칼럼명에 근거한 일반적 해석입니다.

공정 데이터 컬럼: 계량·압력·위치

나머지 측정 컬럼도 공정 의미를 고려해 처리 대상을 선택합니다.

계량

계량시간 — 계량 소요 시간
계량시작점 — 계량 시작 측정값
계량시작위치 — 시작 시점 위치
계량종료점 — 종료 지점 측정값

압력·속도

최대사출압 — 최대 사출 압력
전환압력 — 전환 시점 압력
최대사출속도 — 최대 사출 속도
감압시간 — 감압 소요 시간

쿠션

최소쿠션 — 사출 후 스크루 앞쪽에 남는 수지량 관련 측정값

제거·대체 전 컬럼 중요도와 결측 발생 원인을 확인합니다.

세부 단위·정의는 제조 공정 데이터 사전으로 별도 확인이 필요합니다.

삭제 전 기준선: 실제 결측 현황

15_01 공정 CSV의 250행·22열에서 결측은 12개 컬럼에 분포합니다.

결측 적음

사출압력 1개 (0.4%)
스크루위치 3개 (1.2%)
전환위치 5개 (2.0%)
계량시간 9개 (3.6%)
계량시작점 9개 (3.6%)

중간 결측

최대사출압 34개 (13.6%)
전환압력 34개 (13.6%)
계량시작위치 34개 (13.6%)
스크루속도 60개 (24.0%)
최소쿠션 68개 (27.2%)

결측 비율 높음

계량종료점 109개 (43.6%)
감압시간 109개 (43.6%)

최대사출속도 결측은 0개입니다.

전체 결측 475개
결측 없는 행 76개

삭제 예시와 임계값은 이 실제 분포를 기준으로 해석해야 합니다.

dropna: 행·열 삭제

기본 dropna는 행 단위로 결측이 하나라도 있으면 그 행을 제거합니다.

행 삭제

df.dropna()

250행 × 22열 → 76행 × 22열

결측이 없는 행만 남깁니다. 행이 174개 줄어 정보 손실이 큽니다.

열 삭제

df.dropna(axis=1)

250행 × 22열 → 250행 × 10열

결측이 있는 컬럼을 모두 제거합니다. 표본 행은 보존하지만 유용한 측정 변수도 사라질 수 있습니다.

판단 기준

결측이 몇몇 행에 집중되면 행 삭제 검토

특정 컬럼에 결측이 몰리면 열 삭제 검토

삭제 후 shape와 분석에 필요한 변수의 보존 여부를 확인합니다.

how·thresh·subset으로 삭제 기준 조절

옵션은 '어떤 행을 남길지'를 구체적으로 정합니다.

how='all'

모든 칸이 결측인 행만 삭제

현재 데이터 결과:
250행 × 22열 유지

모두 비어 있는 행이 없기 때문입니다.

thresh=20

값이 20개 이상인 행만 유지

250행 중 162행 유지

'결측이 20개 이하'가 아니라, 실제 값이 최소 20개 있어야 한다는 뜻입니다.

subset=['불량여부']

지정한 컬럼의 결측만 확인

이 데이터의 불량여부에는 결측이 없어 250행 모두 유지됩니다.

대상 라벨을 기준으로 분석할 때 사용할 수 있습니다.

결측 비율 기준으로 컬럼 선택

비율 > 40% 조건을 실제 CSV에 적용하면 어떤 컬럼이 선택될까요?

비율 계산

비율 = df.isna().sum() / len(df)

각 컬럼의 결측 개수를 전체 250행으로 나눕니다.

40% 초과 기준은 결측 100개 초과입니다.

실제 선택 결과

계량종료점 109개 · 43.6%
감압시간 109개 · 43.6%

두 컬럼을 제거하면 250행 × 20열입니다.

데이터 확인 주의

최대사출속도 결측은 0개입니다.

'최대사출속도'가 40% 초과 컬럼이라는 주석 예시는 이 입력 데이터와 일치하지 않습니다.

결측 비율을 실행해 확인하세요.

스크립트의 실습 3은 실제 결측 컬럼을 동적으로 계산합니다.

삭제 손실 비교: 몇 행이 남는가

행 개수만 비교하지 말고 원본 대비 손실률도 함께 봅니다.

원본

250행
손실률 0.0%

삭제 전 비교 기준입니다.

dropna()

76행
174행 제외
손실률 69.6%

결측이 하나라도 있는 행을
제거합니다.

thresh=20

162행
88행 제외
손실률 35.2%

20개 이상 값이 있는 행을 남깁니다.

삭제가 쉬운 선택이어도 표본 수와 편향에 미치는 영향을 검토합니다.

fillna: 값의 의미에 맞춰 대체

대체는 행을 유지하지만, 선택한 값이 분포와 분석 결과를 바꿀 수 있습니다.

상수·범주형

fillna(상수)

'해당 없음'처럼 실제 의미가 명확할 때만 상수를 사용합니다.

범주형 컬럼은 최빈값(mode()[0])을 사용할 수 있습니다.

평균·중앙값

평균 — 대칭적이고 이상치 영향이 작을 때

중앙값 — 분포가 치우치거나 이상치가 있을 때

대체 전에 실제 분포와 통계량을 비교합니다.

시간·그룹

ffill() — 직전 유효값
bfill() — 다음 유효값

groupby + transform — 설비·제품 그룹 내 통계량

정렬·그룹 키·연속 결측 길이를 먼저 확인합니다.

대체값은 관측값이 아니라 추정값입니다. 필요하면 대체 여부를 별도 표시합니다.

평균과 중앙값: 실제 공정 측정값

현재 입력 파일에서 계산되는 통계량으로 fillna를 설명합니다.

스크루속도

평균 46.89
중앙값 47.42
결측 60개

스크립트는 개념 시연에서
중앙값으로 채운 결과를 만듭니다.

최대사출압

평균 1262.54
중앙값 1260.92
결측 34개

평균·중앙값 각각의 대체 결과에서
결측은 0개가 됩니다.

검증 방법

```
filled = df[col].fillna(df[col].median())
```

filled.isna().sum() == 0 확인

대체 전후 행 수와 분포가 유지되는지
점검합니다.

스크립트의 기존 통계량 주석은 실제 PROC 입력의 출력과 다르므로, 실제 실행값을 기준으로 표시했습니다.

로그 데이터: 최빈값과 앞뒤 값 대체

로그는 16행 × 7열이며, 스크립트는 두 컬럼만 선택해 결측을 채웁니다.

컬럼과 결측

측정시각 · 사출기 · 배럴온도
사출압력 · 스크루속도
누적샷 · 불량여부

실제 NaN:
사출기 1 · 배럴온도 2
사출압력 1 · 스크루속도 1

스크립트 처리

사출기 — 최빈값으로 대체
최빈값: 1호기

측정시각 오름차순 정렬
배럴온도 — ffill() 후 bfill()

두 대상 컬럼의 NaN은 각각 0개가 됩니다.

처리 범위의 한계

사출압력의 NaN 1개와 스크루속도의 NaN 1개는 남습니다.

0 압력 2건
스크루속도 -999 두 건
배럴온도 999 한 건

스크립트는 이 위장값을 변환하지 않습니다.

로그 전체를 완전 정리한 결과가 아니라, 사출기와 배럴온도 두 컬럼에 대한 예시입니다.

그룹별 대체: 실제 실행 경로를 확인

사출기별 평균을 쓰려면 입력 데이터에 사출기 컬럼이 있어야 합니다.

의도한 처리

```
proc.groupby('사출기')['스크루속도']
  .transform(lambda x: x.fillna(x.mean()))
```

같은 설비 그룹의 평균으로 결측 속도를 채우는 방식입니다.

현재 실제 실행

PROC는 15_01 공정 CSV입니다.

이 입력에는 사출기 컬럼이 없습니다.

따라서 코드의 else 분기에서 스크루속도를 전체 평균으로 채웁니다.

숫자 컬럼 후처리

나머지 숫자형 컬럼의 결측은 각 컬럼 중앙값으로 채웁니다.

최종 결측 총합은 0입니다.

사출기 그룹별 처리를 실습하려면 PROC 경로를 15_02 CSV로 바꾸어 별도로 검증해야 합니다.

데이터 파일이 바뀌면 행·열과 결과도 바뀌므로, 그룹 대체 분기를 다시 확인하세요.

삭제 버전과 대체 버전 비교

코드 주석의 예상값이 아니라 실제 실행값으로 비교합니다.

기준 데이터

코드에서 최대사출속도와 감압시간 컬럼을 제거합니다.

250행 × 20열

최대사출속도는 원래 결측이 없지만 이 단계에서 명시적으로 삭제됩니다.

결측 행 삭제

기준 데이터.dropna()

실제 76행

계량종료점 등 다른 결측 컬럼도 남아 있으므로 삭제 결과가 110행이 아닙니다.

중앙값 대체

기준 데이터.fillna(중앙값)

250행

행을 보존하지만, 각 대체값이 원래 측정값이 아님을 고려해야 합니다.

실제 출력: 제거 버전 76행 · 대체 버전 250행. 코드 주석의 '110'은 현재 입력과 맞지 않습니다.

캡스톤 처리와 결과 저장

스크립트의 최종 작업은 지정 컬럼 삭제 후 남은 수치형 결측을 중앙값으로 대체합니다.

처리 순서

1. 최대사출속도·감압시간 삭제
2. 숫자형 컬럼별 중앙값 대체
3. 전체 결측 개수와 shape 확인
4. CSV 저장

결과: 0개 결측 · 250행 × 20열

주의할 삭제 기준

현재 공정 CSV의 결측률 40% 초과 컬럼은 계량종료점·감압시간입니다.

캡스톤 코드는 최대사출속도·감압시간을 직접 삭제합니다.

동적 선택과 고정 선택은 결과가 다릅니다.

저장 파일

사출성형_처리완료.csv

index=False
encoding='utf-8-sig'

저장 경로를 지정하지 않아 실행 당시 현재 작업 폴더에 생성됩니다.

원본 CSV는 덮어쓰지 않습니다. 저장 파일의 폴더와 인코딩을 실행 환경에서 확인합니다.

코드와 데이터를 함께 점검할 항목

PPT·주석·스크립트·실행 결과가 일치해야 실습 결과를 신뢰할 수 있습니다.

입력 경로

15_02 스크립트도 15_01 공정 CSV를 읽습니다.

별도 15_02 CSV는 현재 사용되지 않습니다.

실제 데이터 파일과 그룹 컬럼을 확인합니다.

주석과 결과

40% 초과 컬럼의 주석이 실제 계산과 다름
평균·중앙값 주석값이 실제 출력과 다름
비교 실습의 예상 110행과 실제 76행이 다름

로그 처리 범위

사출기·배럴온도만 결측 대체
사출압력·스크루속도 결측은 남음
0·-999·999 위장값은 그대로

전체 로그를 정리했다고 표현하지 않습니다.

이 자료는 현재 코드를 설명하며, 주석의 잘못된 값이나 처리 로직을 임의로 바꾸지는 않았습니다.

정리: 보존할 데이터와 처리 근거

결측 확인에서 출발해 방법을 선택하고, 결과를 수치로 검증합니다.

삭제

dropna 옵션으로 기준을 명확히
원본·행·열 크기 비교
행 손실률 계산
컬럼 중요도와 결측 위치 검토

대체

수치·범주·시간·그룹별로 선택
평균·중앙값의 실제 출력 확인
정렬과 그룹 키 점검
위장값은 먼저 NaN 처리 검토

검증

남은 결측 합계 확인
실제 실행값과 주석 비교
저장 경로·행·열·인코딩 확인
처리 가정을 결과와 함께 기록

핵심: 데이터가 보존된 양과 새로 추정해 채운 값을 구분해서 설명합니다.