설비 고장을 예측하는 AI 데이터 분석

이상치 처리

이상치 개념과 사분위수

posco

CONTENTS

목차

01	이상치 이해 — 개념과 처리 흐름	개념·프레임
02	분포와 사분위수 — 분포 통계와 사분위수 구하기	개념
03	직접 분석 실습 — 손으로 확인하는 분포와 분위수	실습

posco

01

이상치 이해

이상치 개념과 처리 흐름

posco

다이캐스팅 주조 공정 이해 — 도메인 노트

데이터를 읽기 전, 이 설비가 무엇을 재는지 먼저 이해

① 공정

다이캐스팅은 녹인 금속을 고압으로 금형에 주입해 부품을 성형하는 주조 방식. 한 번의 주입을 샷이라 부른다.

② 핵심 변수

실린더압력은 금속을 밀어넣는 유압, 사이클타임은 한 샷에 걸린 시간, 비스킷두께는 잔류 금속, 형체력은 금형을 무는 힘을 뜻한다.

③ 정상과 이상

정상 샷은 사이클타임 20~35초에 압력이 일정 범위를 유지한다. 잼이나 미충전이 생기면 사이클타임이 급증하고 압력이 벗어난다.

④ 왜 이 분석

대부분이 정상이고 이상은 드물게 튄다. 그래서 사분위수와 IQR로 가운데 절반을 기준 삼아 벗어난 샷을 이상 후보로 골라낸다.

posco

이상치란 무엇인가

다른 값들과 크게 동떨어진 값 — 설비 데이터에서는 그 자체가 고장 신호일 수 있는 대상

이상치는 다른 값들과 크게 동떨어진 값

예: 모터 온도 72·75·78도 사이에 갑자기 찍힌 250도, 진동 평소 3에 한 번 찍힌 12

설비 데이터에서는 그 자체가 고장 신호일 수 있음

발견 즉시 삭제가 아니라 멈춰서 살펴볼 대상

posco

이상치 — 오류일까 신호일까

데이터만 봐서는 단번에 못 가림 — 일단 찾아내고 그다음에 판단하는 순서

오류 가능성

센서 고장이나 입력 실수로 잘못 들어온 값

센서가 헐거워져 -5도가 찍히는 식 — 버려야 할 잡음

설비 상태와 **무관**한 값

신호 가능성

설비가 실제로 평소와 다르게 동작한 값

베어링이 닳아 진동이 커지는 식 — 가장 찾고 싶은 단서

설비가 진짜 그런 상태였던 값 — **고장 단서**

posco

이상치가 생기는 원인

원인은 크게 두 갈래 — 측정·기록 오류와 실제 이상 동작

01 · 측정·기록 오류

센서·통신·입력 단계에서 잘못 들어온 값

센서 노후, 접촉 불량, 통신 끊김, 단위 혼동, 자리 입력 실수

예: 75를 750으로 입력, 섭씨를 화씨로 혼동

02 · 실제 이상 동작

설비가 진짜로 평소를 벗어난 값

베어링 마모, 냉각 불량, 윤활 부족으로 값이 평소를 벗어남

센서가 틀린 게 아니라 설비가 진짜 그랬다는 뜻

원인을 알면 판단이 쉬워진다

같은 250도라도 센서 오류인지 실제 과열인지는 숫자만으로 알 수 없음

POINT 01

숫자만으로는 결론 불가 — 동떨어진 값을 일단 찾아내기

POINT 02

어느 쪽인지 판단하는 단계를 따로 두기

POINT 03

원인을 미리 알면 어떤 값을 만났을 때 더 빠른 가늠 가능

노이즈 이상치와 신호 이상치

잡음은 정리, 신호는 보존 — 지우면 고장 흔적까지 함께 사라짐

노이즈성

설비 상태와 무관하게 잘못 들어온 잡음, 정리 대상

예: 온도 -5도처럼 물리적으로 불가능한 값 — 어떤 설비도 영하로 정상 가동되지 않음

신호성

설비가 실제로 달라져 나타난 값, 고장 단서

예: 진동 12 — 물리적으로 가능한 값이고 평소와 다를 뿐, 지우면 고장 흔적이 소실

이상치 발견 시 던질 질문

지울까 말까가 아니라 노이즈인가 신호인가를 먼저 묻기

지울까 말까가 아니라 노이즈인가 신호인가를 먼저 질문

물리적으로 불가능하면 노이즈, 가능한데 평소와 다르면 신호

판단에는 설비를 아는 도메인 지식이 함께 필요

이 질문 하나만 몸에 익혀도 데이터를 대하는 태도가 완전히 달라짐

posco

이상치를 무조건 지우면 안 되는 이유

원칙은 발견 즉시 삭제가 아니라 발견 후 판단

고장은 평소와 다른 상태에서 발생 — 그 순간이 곧 이상치

다 지우면 고장을 알려 주던 단서까지 함께 소실

원칙은 발견 즉시 삭제가 아니라 발견 후 판단

posco

발견 후 신중한 처리

노이즈는 정리, 신호로 의심되면 따로 표시 후 보존

PROCESS 01

노이즈로 확인된 것만 정리, 신호로 의심되면 보존

PROCESS 02

표시는 이상 의심 구간 컬럼에 1로 기록

PROCESS 03

이 한 단계가 고장을 놓치느냐 잡느냐를 가름

결측치 vs 이상치

값이 비었는가, 값은 있으나 동떨어졌는가가 본질적 차이

구분	결측치	이상치
상태	값이 비어 있음	값이 있으나 동떨어짐
표시	**NaN**	**채워진 숫자 (예: 250)**
찾는 법	**isna()**	**isna()로 못 찾음**

> 이상치는 비어 있지 않아 isna로 못 찾음 — **얼마나 동떨어졌는지**를 따져야 함

posco

결측치와 이상치는 처리에서 이어진다

찾는 법은 달라도 처리 단계에서는 서로 손을 잡는 사이

PROCESS 01

이상치 처리의 한 방법이 그 값을 NaN으로 바꾼 뒤 채우기

PROCESS 02

믿을 수 없는 값을 일단 비우고 주변 값으로 메우기

PROCESS 03

찾는 법은 달라도 처리 단계에서는 서로 손을 잡는 사이

250도 노이즈 값을 NaN으로 바꾼 다음 중앙값이나 앞뒤 값으로 채우는 방식 — 다음 시간에서 다시 다룸

이상치가 평균을 왜곡한다

70도대 데이터에 250·300이 섞이면 평균이 115까지 치솟음

지표	값	해석
평균	**약 115.6도**	이상치에 끌려 올라감 — 큰 값이 합계를 위로 당김
중앙값	**76.5도**	실제 분위기 — 양 끝값에 흔들리지 않음
표준편차	**약 90.5**	비정상적으로 큼 — 현실과 동떨어진 값

평균을 평소 온도라고 잘못 받아들이면 **정상 범위와 경고 기준이 모두 틀어짐**

posco

평균-중앙값 격차는 이상치 신호

두 값을 항상 나란히 확인하는 작은 습관 하나가 큰 오해를 막음

중앙값은 가운데 값이라 양 끝 이상치에 거의 흔들리지 않음

평균 115 vs 중앙값 76.5 — 큰 격차 자체가 이상치 신호

데이터를 받으면 두 값을 항상 나란히 확인

posco

정상 범위와 이상 범위

이상치를 찾는다는 것은 정상 범위의 경계선을 긋는 일

01 · 경계 긋기

아래쪽 하한과 위쪽 상한 사이가 정상, 바깥이 이상

02 · 예시

정상을 60~90도로 정하면 250도와 -5도는 자동으로 이상

03 · 핵심

동떨어졌다고 말하려면 먼저 보통의 범위를 정해야 함

posco

범위를 정하는 두 방법

오늘 배우는 IQR이 자동 계산 방식의 대표

01 · 수동 지정

현장 전문가가
정상 범위 직접 지정

가장 믿을 만하나 컬럼이 많으면 비현실적

전문가 지식 기반 · 도메인 의존

02 · 자동 계산

데이터의 가운데 절반을
기준으로 경계 결정

컬럼이 많아도 한 번에 적용 — 오늘 배울 IQR 방식

분포 기반 · 데이터 스스로의 경계

posco

이상치를 찾는 세 가지 접근

세 방법은 경쟁이 아니라 상황 따라 함께 쓰는 도구

01 · 눈으로

사람이 직접 훑어 찾기

표나 그래프를 사람이 직접 훑어 찾기

데이터가 적을 때 충분

감각 훈련 · **검증의 기준**

02 · 통계로

분포를 계산해 자동 선별

분포 계산으로 기준 넘는 값 자동 선별

오늘 배울 **IQR**이 대표

자동·일관 · 대량 컬럼 가능

03 · 모델로

패턴 학습으로 판단

패턴을 학습시켜 평소와 다른 데이터 판단

이후 학습에서 다룰 머신러닝 영역

여러 센서 동시 분석

posco

오늘의 위치 — 통계 기반 IQR

IQR을 이해하려면 분포 읽기가 먼저

세 접근 중 **통계 기반**, 그중 가장 기본인 **IQR**을 학습

IQR을 쓰려면 **데이터 분포**를 숫자로 읽는 법이 먼저

세 방법은 경쟁이 아니라 **상황 따라 함께 쓰는 도구**

오늘 후반부에 분포와 사분위수를 배우는 이유 — IQR을 이해하려면 분포 읽기가 먼저

posco

이상치 처리 3단계 흐름

탐색 → 판단 → 처리, 세 단계의 흐름

STEP 1

탐색

동떨어진 값의 위치를 찾아냄. 오늘의 IQR이 담당

자동 위치 탐색

STEP 2

판단

노이즈인지 신호인지 결정. **도메인 지식** 필요

가장 중요·어려운 단계

STEP 3

처리

제거·보정·결측 변환. 신호는 보존

판단 결과 따라 처리

탐색은 자동, 판단은 사람·도메인, 처리는 결과에 따라 — 세 단계를 분리해 생각하는 일이 핵심

posco

흐름의 핵심 — 판단을 건너뛰지 않기

가장 중요한 것은 판단 단계를 생략하지 않기

처리는 항상 지우기가 아니라 남기거나 바꿀지 결정하는 일

노이즈는 정리, 신호는 보존 — 같은 이상치도 다르게 처리

가장 중요한 것은 판단 단계를 생략하지 않기

posco

처리는 반복되고 기록된다

일회성 작업이 아니라 꾸준한 관리 활동에 가까움

POINT 01

한 번 하고 끝이 아니라 데이터가 쌓일 때마다 반복

POINT 02

무엇을 왜 노이즈로 또는 신호로 판단했는지 기록이 중요

POINT 03

기록이 있어야 다른 사람도 이해하고 판단 근거를 되짚을 수 있음

02

분포와 사분위수

분포 통계와 사분위수 구하기

posco

데이터를 보는 두 축

이상치는 바로 퍼짐의 바깥 끝에 있음

01 · 중심

데이터가 대체로 어디에 모였나

대표 지표: **평균**, **중앙값**

보통 어느 정도냐는 질문에 답하는 숫자

02 · 퍼짐

중심에서 얼마나 흩어졌나

대표 지표: **범위**, **표준편차**, **IQR**

이상치는 이 퍼짐의 바깥 끝에 위치

posco

같은 평균, 다른 퍼짐

중심과 퍼짐을 반드시 함께 봐야 데이터를 제대로 이해

설비 A · 안정

평균 75도 · 범위 73~77도

좁은 폭으로 모여 있음 — 평소대로 안정적으로 가동 중

설비 B · 불안정

평균 75도 · 범위 50~100도

넓게 흩어져 있음 — 무언가 불안정한 상태

중심만 보면 같은 설비 — **퍼짐을 정확히 재는 일이 곧 이상치를 잘 찾는 길**

posco

이상치에 강한 도구를 쓰자

흔들리는 자로 흔들리는 대상을 재면 기준이 무너짐

관점	✕ 이상치에 약한 값	☑ 이상치에 강한 값
중심	평균	중앙값
퍼짐	범위 · 표준편차	IQR

250·300 섞이면 평균 115·표준편차 90 — 중앙값 76.5, IQR은 **가운데 절반 폭으로 안정적**

posco

최소·최대·범위 읽기

범위 = 최댓값 - 최솟값, 데이터가 퍼진 폭을 한 숫자로 표현

01 · 함수

min은 최솟값, max는 최댓값을 한 줄로 계산

02 · 정의

범위 = 최댓값 - 최솟값, 퍼진 폭을 한 숫자로 표현

03 · 예시

온도 최소 -5도, 최대 300도 → 범위 305도

정상 설비가 305도 폭으로 움직일 리 없음 — 범위가 크다는 것 자체가 이상치 신호

posco

범위의 약점

양 끝만 보니 이상치 하나에 완전히 휘둘림

범위는 양 끝 두 값만으로 계산 → 이상치 하나에 완전히 휘둘림

300도 하나만 있어도 범위가 305도로 확 커짐

그래서 가운데를 보는 사분위수와 IQR로 넘어감

가운데가 얼마나 모였는지는 범위로 전혀 알 수 없음 — 양 끝이 아니라 가운데를 보자는 발상으로 전환

평균과 중앙값의 차이

가운데 사람을 보느냐, 모든 값을 더하느냐의 차이

평균

모든 값을 더해 나눔, 큰 값에 끌려 이상치에 약함

300이 끼면 그대로 합계를 위로 당김 — 값 하나하나가 결과에 직접 더해짐

중앙값

크기순 가운데 값, 양 끝 값 무시해 이상치에 강함

300이 3000으로 커져도 가운데 사람은 그대로 — 흔들리지 않음

posco

이상치 앞에서 무엇을 믿나

사분위수는 중앙값 사고방식을 확장한 것

평균이 실제 분위기와 다르면 이상치에 끌려간 것

이럴 때는 중앙값이 진짜 중심을 더 정확히 알려 줌

사분위수는 이 중앙값 사고방식을 확장한 것

0점 한 명이 끼면 평균은 크게 떨어지지만 중앙값은 거의 그대로

중앙값 다시 보기

값을 크기순으로 정렬한 뒤 한가운데 값을 고르는 방식

STEP 01 · 정렬

값을 크기순으로 정렬한 뒤 한가운데 값을 고르기

STEP 02 · 홀수·짝수

홀수면 가운데 하나, 짝수면 가운데 두 값의 평균

STEP 03 · 주의

구하기 전 반드시 정렬 — 안 하면 엉뚱한 값이 가운데에 옴

예: 70, 72, 75, 78, 80 → 중앙값 75 / 네 개라면 가운데 두 값 72와 75의 평균 73.5

posco

중앙값에서 사분위수로

절반 나누기에서 네 등분 나누기로 확장한 것이 사분위수

중앙값은 데이터를 **절반**으로 나누는 선

절반이 아니라 **네 등분**하면 경계선이 **세 개**

그 세 선이 바로 **사분위수** (Q1, Q2, Q3)

사분위수란 무엇인가

Q1·Q2·Q3 — 데이터를 크기순 네 등분하는 세 경계값

Q1

25%

1사분위수

전체의 **4분의 1 지점** — 이 값보다 작은 데이터가 25%

Q2 · 중앙값

50%

2사분위수 = 중앙값

가운데 지점 — 중앙값과 동일한 값

Q3

75%

3사분위수

전체의 **4분의 3 지점** — Q1~Q3 사이에 가운데 절반

posco

우리 데이터의 사분위수

이상치가 섞여도 사분위수는 가운데만 보기 때문에 거의 흔들리지 않음

Q1

74도

전체의 4분의 1이 **74도보다 작음**

Q3

81.5도

전체의 4분의 3이 **81.5도보다 작음**

가운데 절반

74~81.5

이 사이에 **보통의 온도값**이 모여 있음

평균 115에 비하면 든든한 기준

250·300 같은 이상치가 섞여도 사분위수는 가운데만 보기 때문에 거의 흔들리지 않음

posco

백분위수와 사분위수

백분위수가 큰 개념, 사분위수는 그중 25·50·75만 골라낸 좁은 개념

01 · 백분위수

데이터를 100등분한 지점, 90백분위수면 90%가 그보다 작음

02 · 사분위수

그중 25·50·75퍼센트 세 지점에 이름을 붙인 것

03 · quantile 인자

quantile 괄호 숫자가 바로 이 비율 — 25%는 0.25

posco

quantile 괄호 숫자의 의미

퍼센트를 100으로 나눈 소수를 괄호에 넣기

Q1은 0.25, Q2는 0.5, Q3는 0.75

퍼센트를 100으로 나눈 소수를 괄호에 넣는다고 기억

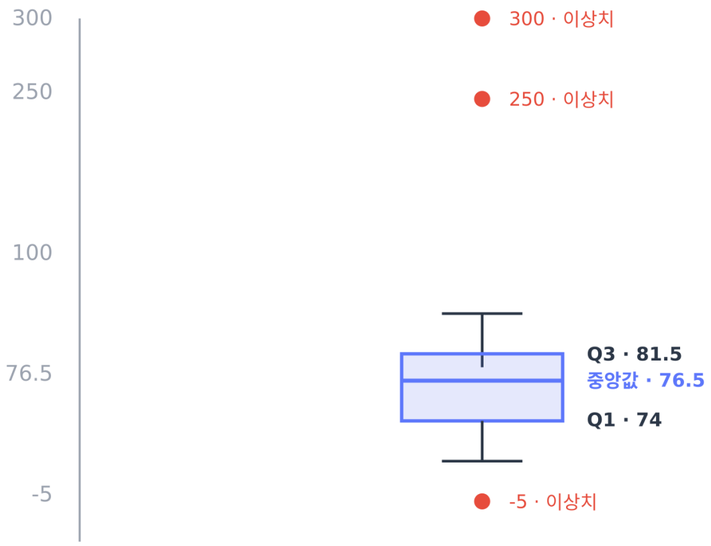
0.9를 넣으면 90백분위수, 0.99면 상위 1% 경계

이 규칙 하나만 외워 두면 어떤 분위수든 자유롭게 구할 수 있음

박스플롯으로 보는 사분위수

상자는 가운데 절반, 상자 속 선은 중앙값, 수염 밖 점은 이상치

BOXPLOT



읽는 법

상자 = Q1~Q3 (가운데 절반)

74에서 81.5에 얇게 자리 잡음

상자 속 선 = 중앙값

데이터의 정중앙 76.5

수염 밖 점 = 이상치

250, 300, -5 — 한눈에 보임

posco

박스플롯은 IQR을 그린 것

오늘은 그리기가 아니라 읽기에 집중

박스플롯의 이상치 기준이 곧 IQR 규칙과 동일

오늘은 그리기가 아니라 읽기에 집중 — 그리기는 이후 학습에서

상자는 가운데 절반, 수염 밖 점은 이상치라는 읽기만 익히기

숫자로 구한 결과와 그림이 일치하는 걸 보면 개념이 단단해짐

posco

quantile()로 사분위수 구하기

컬럼 뒤에 점 찍고 quantile, 괄호에 비율을 넣기

CODE

```
# Q1 = 25%, Q2 = 50% (= 중앙값), Q3 = 75%
Q1 = df["temperature"].quantile(0.25)
Q2 = df["temperature"].quantile(0.5)
Q3 = df["temperature"].quantile(0.75)
print(Q1, Q2, Q3)

# 결과: 74.0 76.5 81.5
```

posco

quantile 한 번에 구하기와 주의점

quantile 인자는 비율 — 반드시 0과 1 사이 소수

CODE

```
# 대괄호로 묶어 세 값 한 번에
print(df["temperature"].quantile([0.25, 0.5, 0.75]))

# 결과:
# 0.25 74.0
# 0.50 76.5
# 0.75 81.5
```

자주 하는 실수

25·50·75를 넣는 경우 — quantile 인자는 반드시 0~1 소수. 25를 넣으면 오류

posco

describe()로 분포 한눈에

개수·평균·표준편차·최소·사분위수·최대를 한 번에 — 데이터를 받자마자 가장 먼저

CODE

```
# 분포 요약 통계를 한 번에
print(df["temperature"].describe())

# count 18.000000
# mean 115.611111
# std 90.500000
# min -5.000000
# 25% 74.000000
# 50% 76.500000
# 75% 81.500000
# max 300.000000
```

posco

describe 읽는 법

청진기처럼 데이터 건강을 빠르게 진단해 주는 함수

항목	값	읽기
`mean`	115.6	이상치에 끌려 높음 — 실제 분위기 아님
`50%`	76.5	실제 분위기 (중앙값) — 평균과 큰 격차
`min / max`	5 / 300	양쪽 모두 비현실적 — 사분위수에서 멀리 벗어남

> 평균-중앙값 큰 격차 = **이상치 신호**, 양 끝값이 사분위수에서 멀면 **비현실적 값** 존재

예지보전 속 이상치 처리

예지보전의 출발점이자 토대는 전처리

01 · 예지보전

데이터로 고장을 미리 알아채 대비하는 일

02 · 출발점

그 출발점이자 토대가 데이터를 깨끗이 하는 전처리

03 · 오늘의 위치

오늘 배우는 결측치·이상치 처리가 모두 전처리에 속함

고장 나고 고치는 게 아니라 미리 알아채 대비하는 일 — 갑작스러운 가동 중단과 비용을 막음

posco

좋은 데이터가 좋은 모델을 만든다

노이즈는 정리하되 신호는 보존 — 오늘의 원칙이 빛을 발하는 자리

노이즈를 두면 모델이 센서 오류를 학습

신호를 다 지우면 모델이 고장 단서를 못 봄

실제 제조 연구도 사분위수로 찾아 중앙값 대체하는 흐름

03

직접 분석 실습

손으로 확인하는 분포와 분위수

posco

실습 1. 주조 데이터 구조·분포 살펴보기

다이캐스팅 설비 데이터를 불러와 구조를 첫 진단

목표

주조 데이터를 불러와 크기·컬럼·자료형을 확인

단계

· read_csv로 데이터를 불러와 head로 앞부분 확인

· shape와 columns로 크기와 컬럼 이름 확인

· info로 자료형과 결측 여부 훑기

예상 결과

202행 7열, 실린더압력·사이클타임 등 컬럼 확인

posco

실습 1. 주조 데이터 구조·분포 살펴보기 정답

다이캐스팅 설비 데이터를 불러와 구조를 첫 진단

CODE · 실습 1

```
df = pd.read_csv('diecasting.csv')
print(df.head())
print(df.shape)          # (202, 7)
print(df.columns.tolist())
df.info()
```

실습 2. 한 컬럼의 최소·최대·범위

실린더압력의 양 끝값과 범위로 퍼짐 확인

목표

한 컬럼의 최솟값·최댓값·범위를 구해 퍼짐 확인

단계

· 실린더압력 열의 최솟값 구하기

· 실린더압력 열의 최댓값 구하기

· 최댓값에서 최솟값을 빼 범위 계산

예상 결과

실린더압력 최소 108·최대 265·범위 157

posco

실습 2. 한 컬럼의 최소·최대·범위 정답

실린더압력의 양 끝값과 범위로 퍼짐 확인

CODE · 실습 2

```
print(df['실린더압력'].min())    # 108.0
print(df['실린더압력'].max())    # 265.0
print(round(df['실린더압력'].max() - df['실린더압력'].min(), 1))   # 157.0
```

실습 3. 정렬해서 이상치 후보 찾기

정렬로 동떨어진 사이클타임을 눈으로 찾아 분류

목표

정렬해 양 끝의 동떨어진 값을 후보로 찾고 분류

단계

· 사이클타임 열을 기준으로 내림차순 정렬

· 위쪽 끝에서 동떨어진 큰 값 찾기

· 각 후보를 정상 상태와 이상 상태로 나누기

예상 결과

6170·652초 등 설비 잼 후보, 정상은 20~35초

posco

실습 3. 정렬해서 이상치 후보 찾기 정답

정렬로 동떨어진 사이클타임을 눈으로 찾아 분류

CODE · 실습 3

```
정렬 = df.sort_values('사이클타임', ascending=False)
print(정렬[['샷', '사이클타임', '상태']].head())
# 6170·652초 = 설비 잼(상태 1), 정상 20~35초
```

posco

실습 4. 평균·중앙값으로 이상치 영향 확인

이상치가 평균을 끌어당기는 정도를 중앙값과 비교

목표

이상치가 평균을 끌어당기는 정도를 중앙값과 비교

단계

· 사이클타임의 평균과 중앙값을 각각 구해 차이 확인

· 상태가 정상인 행만 조건으로 골라내기

· 정상만의 평균이 중앙값에 가까워지는지 확인

예상 결과

평균 64.75 vs 중앙값 22.6, 정상만 평균 27.67

posco

실습 4. 평균·중앙값으로 이상치 영향 확인 정답

이상치가 평균을 끌어당기는 정도를 중앙값과 비교

CODE · 실습 4

```
print(round(df['사이클타임'].mean(), 2))     # 64.75 (이상치에 끌림)
print(df['사이클타임'].median())             # 22.6
정상 = df[df['상태'] == 0]
print(round(정상['사이클타임'].mean(), 2))    # 27.67 (중앙값 근접)
```

실습 5. quantile로 Q1·Q2·Q3

실린더압력의 사분위수를 구하고 Q2와 중앙값 일치 확인

목표

사분위수를 구하고 Q2가 중앙값과 같은지 확인

단계

· 25% 지점 값을 quantile로 구해 Q1 확인

· 50% 지점 값이 중앙값과 같은지 확인

· 75% 지점 값을 구해 가운데 절반 범위 파악

예상 결과

실린더압력 Q1 215.75·Q2 218·Q3 265

posco

실습 5. quantile로 Q1·Q2·Q3 정답

실린더압력의 사분위수를 구하고 Q2와 중앙값 일치 확인

CODE · 실습 5

```
print(df['실린더압력'].quantile(0.25))   # 215.75 (Q1)
print(df['실린더압력'].quantile(0.5))    # 218.0 (Q2가 중앙값)
print(df['실린더압력'].quantile(0.75))   # 265.0 (Q3)
```

posco

실습 6. describe로 격차 큰 컬럼 찾기

describe 표에서 평균-중앙값 격차 큰 이상치 의심 컬럼 찾기

목표

describe 표에서 이상치 의심 컬럼을 찾아 해석

단계

· 여러 공정 컬럼을 describe로 요약

· 요약을 컬럼별로 정리하고 평균과 중앙값 격차 계산

· 격차가 큰 순으로 정렬해 이상치 의심 컬럼 확인

예상 결과

주조압력·형체력·사이클타임 등 격차 큰 컬럼 확인

posco

실습 6. describe로 격차 큰 컬럼 찾기 정답

describe 표에서 평균-중앙값 격차 큰 이상치 의심 컬럼 찾기

CODE · 실습 6

```
요약 = df[['실린더압력','주조압력','사이클타임','비스킷두께','형체력']].describe().T
요약['격차'] = (요약['mean'] - 요약['50%']).abs()
print(요약.sort_values('격차', ascending=False)[['mean', '50%', 'max']].head(3))
# 주조압력·형체력·사이클타임: 격차 큰 이상치 의심
```

posco

실습 7. 여러 컬럼의 가운데 절반 폭 비교

세 컬럼의 Q3-Q1을 비교해 안정·의심 컬럼 구분

목표

세 컬럼의 가운데 절반 폭(Q3-Q1)을 비교

단계

· 세 컬럼의 사분위수를 한 번에 구하기

· 각 컬럼의 75% 값에서 25% 값을 빼 가운데 절반 폭 계산

· 폭이 좁은 안정 컬럼과 넓은 의심 컬럼 구분

예상 결과

폭 실린더압력 49.25·사이클타임 15.12·비스킷두께 6

posco

실습 7. 여러 컬럼의 가운데 절반 폭 비교 정답

세 컬럼의 Q3-Q1을 비교해 안정·의심 컬럼 구분

CODE · 실습 7

```
q = df[['실린더압력', '사이클타임', '비스킷두께']].quantile([0.25, 0.5, 0.75])
print(q)
print(q.loc[0.75] - q.loc[0.25])
# 실린더압력 49.25, 사이클타임 15.12, 비스킷두께 6.0
```